

Resumen


Para la elaboración de este proyecto inicialmente se procedió en la búsqueda del dataset que permitiera construir el clasificador de anomalías de columna vertebral, una vez encontrado se procedió a hacer el tratamiento de los datos que este contenía, se dividió de la mejor manera posible para tener un número equilibrado de elementos de cada clase, es decir, diagnósticos de personas con condiciones normales y anormales, para que así el clasificador pudiese trabajar óptimamente. Para un mejor resultado se realizaron pruebas con los mismos datos en los diferentes tipos de clasificadores disponibles en la librería sklearn de python, además se hizo uso de la técnica de cross validation para posteriormente compararlas. una vez obtenidos los resultados se escogieron los clasificadores más confiables para facilitar el diagnóstico de anomalías vertebrales.

Introducción

En los últimos años las personas que desarrollan anomalías de la columna vertebral son cada vez más numerosas, e incluso el porcentaje de la población que padece esta afección puede verse incrementado en consecuencia de las condiciones generadas por la pandemia del COVID-19, puesto que la falta de actividad física sumado a las largas jornadas laborales y académicas en casa pueden convertirse en factores de riesgo que provocan dicho aumento. Para diagnosticar este tipo de anomalías es necesario una serie de exámenes clínicos junto a la opinión de un profesional de la salud. Con el objetivo de brindar una herramienta para facilitar la detección de anomalías vertebrales se decidió desarrollar este proyecto pensando en las necesidades que afronta el mundo a lo largo de la pandemia y posterior a ella.

Proceso y método

- La información utilizada para este proyecto consiste en dos datasets; en estos se incluyen 6 valores numéricos correspondientes a medidas de ángulos y distancias obtenidas de exámenes de rayos x de cada uno de los pacientes, así mismo estos valores se asociaban a un diagnóstico. En el primer dataset solo se distingue entre paciente con anormalidad y sin anormalidad, mientras que en el segundo se especifica el diagnóstico en aquellos pacientes con anormalidad, ya fuese Espondilolistesis ó Hernia.
- Mediante distintas herramientas dispuestas por las librerías de python: Numpy y Pandas, se inspeccionaron los elementos del dataset, haciendo énfasis en la cantidad de datos que se iban a requerir para el proceso de clasificación. Puesto que el número de datos correspondientes a cada diagnóstico no es equilibrado, y en vista de que no es posible aumentarlos con técnicas propias de machine learning puesto que se trata de datos clínicos, fue necesario realizar algunas operaciones para dividir manualmente la información en cantidades medianamente equilibradas para las diferentes clases.
- Haciendo uso de los datos anteriormente divididos, tomando una cantidad aproximada del 70% de la información total, se procedió a la fase de entrenamiento, en este proceso se implementaron diferentes clasificadores de distintos tipos y con diferentes parámetros por medio de la librería sklearn, esto último con la intención de encontrar un mejor resultado. Para calcular la efectividad de los clasificadores se usa el 30% de la información restante, de esta manera se prueba al clasificador con datos que no conoce, y este debe proporcionar un diagnóstico. Se realiza la comparación con los diagnósticos reales para definir el porcentaje de aciertos de los diagnósticos arrojados por el clasificador.



Resultados

Los valores porcentuales arrojados por cada uno de los clasificadores se presentaron en las gráficas Score Vs Estimator donde se aprecia la fiabilidad alcanzada por cada clasificador implementado.

Gráfico 1. Resultados obtenidos de diferentes clasificadores para el dataset 1.





Gráfico 2. Resultados obtenidos de diferentes clasificadores para el dataset 2.



Conclusiones

Con base en los resultados obtenidos del primer clasificador, es posible afirmar que aunque la mayoría de los resultados son altamente efectivos, para nuestro caso de estudio lo mejor es optar por el estimador SVC cuyos parámetros son los generados por defecto mediante sklearn, mientras que a su vez se aplique la técnica de Cross validation. De esta manera, contando con los datos obtenidos del paciente mediante los respectivos exámenes, y transfiriéndose por el clasificador, tenemos un 84.4% de seguridad para definir si el diagnóstico es efectivamente una anomalía en la columna vertebral o no.

En cuanto al caso presentado en el segundo conjunto de clasificadores se evidencio que la falta de balance de los datos entre las diferentes opciones a clasificar, se incurrió en overfitting provocado a su vez por la poca cantidad de casos de estudio. Esto implica que el segundo clasificador no necesariamente es confiable.

Trabajo Futuro

A lo largo del desarrollo de este proyecto se hizo evidente que el rendimiento de los clasificadores en machine learning dependen directamente de la cantidad de datos de los que se dispone y su respectiva distribución. Para qué un proyecto como este pueda crecer a futuro y aumente su precisión se podría hacer uso de una más alta cantidad de datos, que a su vez están repartidos equitativamente, es decir, un número de registros igual o similar para cada anomalía, y así poder clasificarlas con un error menor.

Información de contacto

Julian Colmenares, Email: juliancolmenares806@gmail.com
Juan Sebastian Leon Rodriguez, Email: juansebastianleon5@gmail.com
Laura Sofía Vargas González, Email: sofia.laura.gonzalez.vargas@gmail.com

Docente: Gustavo Garzón, gustavo.garzón@saber.uis.edu.co

Referencias Bibliográficas (en formato APA)

- Garzón, G. G. (s. f.). Inteligencia Artificial I 2020-1. GitLab Inteligencia Artificial I 2020-1. <https://gitlab.com/biv12ab/academico/cursos-uis/ai/ai-uis-student/>
- Lupum, C. (2020, agosto 1–mayo 9). VertebralColumnDataSet (1.0) [Data set containing values for six biomechanical features used to classify orthopaedic patients.]. Kaggle. <https://www.kaggle.com/caesarlupum/vertebralcolumndataset>
- Berthonnaud, E., Dimnet, J., Roussouly, P., & Labelle, H. (2005). 'Analysis of the sagittal balance of the spine and pelvis using shape and orientation parameters', Journal of Spinal Disorders & Techniques, 18(1):40-47.
- Rocha Neto, A. R. & Barreto, G. A. (2009). 'On the Application of Ensembles of Classifiers to the Diagnosis of Pathologies of the Vertebral Column: A Comparative Analysis', IEEE Latin America Transactions, 7(4):487-496.
- Rocha Neto, A. R., Sousa, R., Barreto, G. A. & Cardoso, J. S. (2011). 'Diagnostic of Pathology on the Vertebral Column with Embedded Reject Optional', Proceedings of the 5th Iberian Conference on Pattern Recognition and Image Analysis (IbPRIA'2011), Gran Canaria, Spain, Lecture Notes on Computer Science, vol. 6669, p. 588-595.