

Resumen

En este trabajo se plantea la implementación de una red neuronal convolucional para detectar si un individuo padece cáncer de colon mediante un análisis de imágenes histopatológicas de tejido del colon. Seguidamente se comparan sus resultados con los de otros métodos de clasificación revisados en los contenidos de la asignatura en curso tales como CSV, RFC, entre otros.

Los métodos utilizados trabajan como es esperado y representan una buena forma de abordar datos compuesto por imágenes, sin embargo, se hace necesario la utilización de una buena equipo de hardware que soporte los costos computacionales de la implementación.

Introducción

El cáncer de colon es un tipo de cáncer que hace parte de las denominadas enfermedades silenciosas que no son fácilmente detectables debido a la similitud de síntomas que muestra un individuo respecto de otros males no severos y que al presentar síntomas notables ya está en una etapa intermedia o avanzada. En el caso de éste cáncer.

Para el año 2020, los cálculos de la Sociedad Americana Contra El Cáncer para este cáncer en los Estados Unidos son de 104,610 casos nuevos. Desde 2007 hasta 2016, la tasa de incidencia entre personas de 55 o más años disminuyó cada año un 3.6%, mientras que mostró un aumento del 2% cada año entre la población menor de 55 años.

De acuerdo con el Observatorio Global del Cáncer, el cáncer de colon cobró la vida, en 2018, de 4.405 personas y representó alrededor de 9.000 nuevos casos en el Colombia. Según el Registro de Cáncer de Cali, el riesgo de este cáncer se había duplicado en los últimos cincuenta años tanto en hombres como en mujeres. El riesgo acumulado (0-84) en Colombia es del 3,6%; significa que una de cada 27 personas podría desarrollar este tipo de tumor.

Proceso y método

El estudio radica en investigación y consulta de trabajos y literatura de las tecnologías utilizadas y de los contenidos de la asignatura en curso. Así pues, mediante la búsqueda de conjuntos de datos en Internet, se construyen modelos de Machine Learning para la clasificación de características relevantes a los datos que conforman el dataset. En este caso particular, se trata un conjunto de imágenes dividido en dos partes iguales siendo la mitad muestras de tejido sano y la mitad restante muestras de tejido enfermo.

Se utilizaron tecnologías comunes en el ámbito de la Inteligencia artificial y más precisamente en el DataScience y Machine Learning tales como Pandas, Keras, Numpy, Scikit-learn, entre otras. Todas ellas implementadas en el lenguaje de programación Python y ejecutadas en el entorno de ejecución proporcionado por Google mediante su servicio Google Colab.

El testeo de los estimadores comprenden métodos estadísticos que son muy utilizados en la literatura, métodos tales como cross-validation y métodos proporcionados por las librerías que comparan la exactitud entre dos elementos como lo es accuracy_score




Figura 1. Esquema general de un árbol de decisión.




Figura 2. Esquema general de una red neuronal convolucional.

Resultados

Se logró implementar de manera funcional los distintos clasificadores planteados los cuales, como se esperaba según la literatura, presentan diferentes resultados en cuanto a precisión.

Se encontró que el estimador que presenta mayor precisión en los cálculos es la CNN como se esperaba y por tanto representa el mejor método para trabajar datasets de imágenes.


Se observó que a medida que se varían las capas de la CNN así mismo se obtienen diferente precisión, de manera tal que es pertinente adecuar la red neuronal dependiendo del conjunto de datos.

Se observó que el tiempo de ejecución y costo computacional de cada clasificador es directamente proporcional a la precisión obtenida.

Tabla 1. Resultados de los clasificadores implementados

Estimador	Accuracy
Convolutional Neural Network CNN	0.8840000033378601
Super Vector Classifier SVC	0.819 (+/- 0.02650)
Random Forest Classifier	0.770 (+/- 0.03094)
Gaussian Naive Bayes GNB	0.749 (+/- 0.01466)
Decision Tree Classifier DTC	0.620 (+/- 0.03667)

Figura 3. Muestra de los resultados obtenidos por la CNN



Conclusiones

- Los resultados obtenidos en los experimentos indican que el mejor método para clasificar datasets compuestos por imágenes es el de Deep Learning, en este caso mediante la red neural.
- Es recomendable ajustar la configuración de las diferentes capas de la CNN dado que el resultado varía según dichos ajustes.
- Los distintos métodos de clasificación presentan diferente precisión en los cálculos siendo el más cercano, y costoso, a la CNN, el clasificador CSV y siendo el más impreciso el DTC.
- El presente proyecto permite establecer un buen punto de partida para la aplicación sencilla de herramientas de clasificación a imágenes de células o tejidos del cuerpo humano.
- Se lograron resultados óptimos, sin embargo, es evidente la necesidad de hardware de cómputo con grandes prestaciones para abordar problemas o situaciones con conjuntos de datos mucho más grandes que el propuesto en este trabajo.

Trabajo Futuro

- Como posible mejora a corto y mediano plazo se plantea el diseño, desarrollo e implementación de herramientas con interfaz amigable que permita utilizar estos métodos de clasificación de manera práctica y sencilla para uso de distinto tipo de público.
- Otro aspecto a abordar consiste en utilizar en mayor profundidad métodos estadísticos para brindar un nivel mayor de validez de los estudios.
- Además, se plantea la implementación de métodos de Machine Learning de regresión para obtener predicciones de esa manera.

Información de contacto

Miguel Duarte, miguel.duarte1@correo.uis.edu.co
Docente: Gustavo Garzón, gustavo.garzon@saber.uis.edu.co

Referencias Bibliográficas (en formato APA)

- Borkowski, A. A., Bui, M. M., Thomas, L. B., Wilson, C. P., DeLand, L. A., & Mastorides, S. M. (2019). Lung and Colon Cancer Histopathological Image Dataset (LC25000). arXiv preprint arXiv:1912.12142
- Gulli, A., & Pal, S. (2017). Deep learning with Keras. Packt Publishing Ltd.
- Brownlee, J. (2020, 2 agosto). A Gentle Introduction to k-fold Cross-Validation. Machine Learning Mastery. <https://machinelearningmastery.com/k-fold-cross-validation/>
- P. (2020, 3 julio). Malaria Cell Image Detection Using CNN acc>95%. Kaggle. <https://www.kaggle.com/pradheepri/malaria-cell-image-detection-using-cnn-acc-95/data>