

Resumen

Las lesiones cutáneas son áreas de la piel que tienen un crecimiento o apariencia anormales en comparación con el área circundante. A menudo son protuberancias o parches y pueden deberse a una amplia gama de causas, tan inofensivas como un pequeño rasguño o tan graves como el cáncer de piel. Este trabajo propone una tarea de clasificación de siete clases de lesiones cutáneas del conjunto de datos HAM10000 utilizando aprendizaje profundo sobre la red neuronal convolucional ResNet50 usando las técnicas de aumento de datos, transferencia de aprendizaje y ajuste fino; los resultados son prometedores obteniendo una exactitud del 90.33%.

Introducción

Una lesión cutánea es una zona de la piel que es distinta a la piel que la rodea, existen dos categorías de lesiones cutáneas, primarias y secundarias. Las lesiones cutáneas primarias están presentes al nacer, adquiridas durante la vida de una persona o presentes al inicio de una enfermedad. Una lesión cutánea secundaria ocurre después de una lesión cutánea primaria. El tratamiento de las lesiones cutáneas benignas consiste en la destrucción o eliminación mediante de una amplia variedad de técnicas. La extirpación de una lesión cutánea puede variar desde una simple biopsia, raspado o afeitado de la lesión, hasta una escisión radical que puede sanar por sí sola.

Algunas lesiones cutáneas pueden detectarse como cáncer y aumentan cada año entre un 3% y un 7% [1], a pesar de que la tasa de mortalidad se ha estabilizado, todavía representa una morbilidad notable y un costo de tratamiento sustancial [2], es por esto que el diagnóstico de lesiones cutáneas en una etapa temprana es una tarea importante en la actualidad.

Este trabajo propone un método que funciona sobre el conjunto de datos HAM1000 utilizando la red neuronal convolucional profunda ResNet50, aplicando técnicas como el aumento de datos, el aprendizaje por transferencia y el ajuste fino para mejorar el rendimiento y aumentar la exactitud.

Proceso y método

Esta propuesta trabajó sobre el conjunto de datos HAM10000 [3] que consta de 10015 imágenes de lesiones cutáneas organizadas en 7 clases como se observa en la Figura 1, queratosis actínicas y carcinoma intraepitelial (Akiec), carcinoma de células basales (Bcc), queratosis benigna (Bkl), dermatofibroma (Df), melanoma (Mel), nevos melanocíticos (Nv) y lesión vascular (Vasc). Estos datos clínicos fueron tomados en hombres y mujeres entre 5 y 80 años de edad, las imágenes fueron recopiladas de dos sitios, el Departamento de Dermatología de la Universidad Médica de Viena, Austria y la práctica de cáncer de piel de Cliff Rosendahl de Queensland, Australia.

Las técnicas implementadas en este trabajo fueron, aumento de datos para solucionar el desequilibrio de las clases, transferencia de aprendizaje utilizando la arquitectura ResNet50 [4] preentrenada con el conjunto de datos de IMAGENET [5] y finalmente ajuste fino para entrenar el último bloque convolucional. El modelo fue entrenado con 10 épocas y una distribución de datos para entrenamiento, validación y prueba de 80%, 10% y 10% respectivamente.




Figura 1. Clases del conjunto de datos HAM10000

Resultados

Los resultados obtenidos muestran que se obtuvo un buen desempeño por parte del modelo en la tarea de clasificación, alcanzando una exactitud del 90.33%, una precisión del 90.16 %, una exhaustividad del 90.33 % y un valor F1 del 90.21%.

La Figura 2 muestra la matriz de confusión que proporciona los resultados de la clasificación en los datos de prueba para las siete clases. Las clases predichas están en el eje vertical y las clases verdaderas en el horizontal. Se puede observar que los valores más altos se concentran en la diagonal principal, lo que indica una clasificación correcta.

La Figura 3 muestra el cambio en el valor de exactitud a medida que aumentan las épocas para los datos de entrenamiento y validación. Nótese que la exactitud aumenta constantemente con el número de épocas, evidenciando un comportamiento continuo en los datos de entrenamiento y un incremento relativamente suave en los datos de validación.

La Figura 4 muestra la pérdida a través de las épocas. De la misma forma, se evidenciaron curvas suaves con tendencia a disminuir continuamente en los datos de entrenamiento, mientras que en los datos de validación la pérdida aumenta ligeramente.

Figura 2. Matriz de confusión




Figura 3. Epocas vs Exactitud





Figura 4. Epocas vs Pérdida



Conclusiones

Este trabajo presentó un enfoque para clasificar lesiones de piel del conjunto de datos HAM10000, obteniendo una exactitud cercana a los métodos propuestos del estado del arte.

Principalmente, el método propuesto se basa en el aprendizaje por transferencia a través del ajuste fino en la red neuronal convolucional ResNet50, previamente entrenada con el conjunto de datos ImageNet.

La combinación de técnicas como el aumento de datos evita que el clasificador tienda a favorecer más a aquellas clases con mayor número de imágenes y nos permite clasificar el conjunto de datos HAM10000 en siete categorías con una alta exactitud del 90.33 %.

Los resultados obtenidos demuestran una vez más que el aprendizaje profundo y de transferencia son una alternativa prometedora para un soporte rápido y preciso de las decisiones médicas a través del diagnóstico asistido por computadora.

Trabajo Futuro

Un enfoque futuro podría implementar un modelo bilineal utilizando dos arquitecturas, sumado a un preprocesamiento de las imágenes que permita mejorar sus características mediante técnicas como la ecualización de histograma adaptativo con contraste limitado y que permitan delimitar los bordes de la lesión cutánea y proporcionar una representación matemática precisa y suave de este mediante métodos de B-spline.

Información de contacto

Camilo Andrés Calderón Carrillo, Email: camilo2170090@correo.uis.edu.co
Jessica Paola Escobar Pérez, Email: jessica2171713@correo.uis.edu.co

Docente: Gustavo Garzón, gustavo.garzon@saber.uis.edu.co

Referencias Bibliográficas

- Leiter, U., Eigentler, T., & Garbe, C. (2014). Epidemiology of skin cancer. In Sunlight, vitamin D and skin cancer (pp. 120-140). Springer, New York, NY.
- Apalla, Z., Lallas, A., Sotiriou, E., Lazaridou, E., & Ioannides, D. (2017). Epidemiological trends in skin cancer. Dermatology practical & conceptual, 7(2), 1.
- Tschandl, P., Rosendahl, C., & Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. Scientific data, 5, 180161.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778).
- Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. (2009, June). Imagenet: A large-scale hierarchical image database. In 2009 IEEE conference on computer vision and pattern recognition (pp. 248-255). Ieee.