

Resumen

La cardiocardiografía es un examen fetal que tiene como objetivo determinar el grado de bienestar del feto. Este monitoreo fetal es muy común realizarlo, sin embargo, la determinación de un diagnóstico no es muy clara en algunas ocasiones. Para efectos prácticos, se determinó un modelo que sirve como apoyo al personal de esta área. El modelo se escogió a partir de un grupo de estimadores entrenados con un dataset que cuenta con más de 2000 cardiocardiografías. Este, cuenta con un 94% de precisión y se ajusta a las métricas de evaluación relevantes en medicina. Finalmente, se pudo obtener un modelo que generalizó de manera satisfactoria el problema y sirve como soporte para el área de la salud.

Introducción

En la actualidad se presentan numerosas enfermedades y accidentes que incurren en la vida de las personas, lo cual produce un acaparamiento de gran magnitud de los trabajadores en la salud. Esto puede generar de forma significativa un agotamiento y estrés mental en dichos empleados, llevando a dar un diagnóstico errado en algunas ocasiones. Por ende, un proceso tan importante como el nacimiento de un ser humano, requiere precisión al momento de realizar una evaluación correcta.

La cardiocardiografía es (normal, sospechoso o patológico) un examen médico, que permite al encargado de la salud del feto ver el análisis cardiaco del este. Además, muestra las contracciones uterinas que derivan en un diagnóstico básico del estado del embrión. Con esto en mente, se plantea realizar un diagnóstico automático que sirva como apoyo al personal médico, mediante la ayuda de una inteligencia artificial la cual clasifica en 3 estados el diagnóstico del feto.



Proceso y método

Con el objetivo de obtener un modelo que pudiera generalizar el problema de una manera efectiva, se trabajó con un dataset con información obtenida a partir de un ensayo clínico aleatorio. Los datos, fueron extraídos de cardiocardiografías realizadas a fetos de mujeres en su última etapa de embarazo.

Al iniciar, fue necesario eliminar las columnas con datos que no aportaran de manera significativa al problema, las decisiones fueron tomadas a partir de una investigación previa. El desbalance de clases era notorio, por lo tanto, se debió emplear una técnica de sobremuestreo denominada SMOTE, con el fin de crear muestras artificiales de las clases minoritarias.

Luego de haber realizado el preprocesamiento, se entrenaron diferentes estimadores con el nuevo dataset. Cada estimador fue evaluado con diferentes métricas, dando relevancia a evaluadores como f1-score, recall y precision.




Figura 1. Ejemplo de cardiocardiografía.



Figura 2. Ecografía 3D.

Resultados

Se encontró un modelo confiable capaz de generalizar el problema de clasificación del monitoreo fetal.

Entre el grupo de modelos entrenados, se tuvo como prioridad la métrica de evaluación "precision", debido a que es la que mejor se adapta al problema. Teniendo en cuenta esto, el mejor modelo se obtuvo a partir de un estimador de tipo Random Forest. A pesar de que la red neuronal tuvo el mejor puntaje con accuracy score, no obtuvo los mejores resultados con los otros evaluadores.


En cuanto a la determinación del valor de k-fold, no se encontraron puntajes sobresalientes entre 4 y 16. El valor asignado fue 10.

Al ser un problema con alta dimensionalidad (18), se creía pertinente la aplicación del Principal Component Analysis, sin embargo, a la hora de disminuir dimensiones no se encontraron mejores resultados.

Tabla 1. Puntaje de diferentes modelos con accuracy score.

Modelo	Accuracy Score
Decision Tree	0.917
SVM	0.818
Random Forest	0.949
Neural Network	0.974

Gráfico 1. Puntaje de diferentes modelos con la métrica precision.



Conclusiones

- Al ser un problema en el área de la medicina, es más relevante la precisión a la hora de clasificar las clases patológicas que las normales, por lo tanto, es de mayor importancia los resultados en la matriz de confusión y los porcentajes en métricas como "precision" que los resultados del accuracy score.
- Se cumplió el objetivo planteado, ya que se halló un modelo capaz de generalizar el problema y sirve como apoyo al personal médico.
- El estimador que mejor se ajustó al problema fue el Random Forest, con un accuracy score del 94% y con valores muy cercanos al 100% con otras métricas, en segundo lugar quedó la red neuronal.
- Al intentar reducir dimensiones, no se encontraron mejoras, por lo tanto, los datos y columnas usadas son representativas y aportan a la clasificación.
- El sobremuestreo para evitar el desbalance de clases, aportó de manera positiva y significativa a los resultados de la clasificación.

Trabajo Futuro

Para ampliar el rango de factores que afectan a la salud del feto existen otras pruebas con distintas variables. Estas en un futuro podrían ser incorporadas para conocer de forma mas segura el estado del embrión. Por otro lado, es recomendable entrenar el modelo con más datasets, ya que, al ser seres humanos, la variabilidad es muy alta y con pocos datos no se genera un modelo muy confiable.

Información de contacto

Nombre: Fredy Alejandro Mendoza Lopez, Email: ifredomendoza@gmail.com
Nombre: Orlando Alberto Moncada Rodriguez, Email: dianorly@hotmail.com

Docente: Gustavo Garzón, gustavo.garzon@saber.uis.edu.co

Referencias Bibliográficas

- Cardiocardiografía. (s. f.). Saludemia. Recuperado 6 de agosto de 2020, de <https://www.saludemia.com/-/prueba-cardiocardiografia>
- Aurélien, G. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed. ed.). O'Reilly Media.
- Brownlee, J. (2020, 7 junio). *SMOTE for Imbalanced Classification with Python*. Machine Learning Mastery. <https://machinelearningmastery.com/smote-oversampling-for-imbalanced-classification/>