

Resumen

El proyecto consistió en predecir la opinión basada en una review de una película. El trabajo investigativo estribó de la comparación de los resultados obtenidos por un dataset de imdb de 50000 reseñas, de texto plano alojado en Kaggle, con el mismo dataset previamente tratado alojado en Tensorflow. Para lograr esto, el primer dataset fue preprocesado para quedar en iguales condiciones al de tensorflow para ser entrenados en la red neuronal en iguales condiciones.

Con ambos datasets se obtuvieron resultados satisfactorios y similares, que demuestra la efectividad del modelo de la red neuronal para este problema.

Introducción

Si bien cada año es más popular ver películas por plataformas de streaming, actualmente, estando cerrados los lugares donde hay conglomeración de gente, es obligatorio para el aficionado que quiere ver películas de estreno verlas de forma digital.

Este usuario se apoya de la calificación que otros usuarios le dan a la película en diferentes plataformas (rotten tomatoes, imdb, etc), evitando así ver películas indeseadas. Sin embargo, el sistema de calificación suele usarse para sabotear el puntaje de una película por cuestiones ajenas a la calidad de la película en sí, por lo tanto, es difícil confiar plenamente en la objetividad del puntaje de una película, incluso en una plataforma con millones de usuarios como lo es IMDb. No solo es importante la calificación para los usuarios sino también para el mundo del cine en general, debido a la influencia que tiene en este una plataforma internacional como IMDb.

Es por esto que se cuenta con las reseñas de los usuarios, cuyas opiniones permiten una realimentación más certera y permiten que el usuario pueda tomar una mejor decisión.

Por esto, IMDb cuenta con diferentes métricas para calificar películas, entre esas, las reseñas de los usuarios. Por esto, el presente trabajo realizado sería una aproximación del algoritmo (que es desconocido) que utiliza IMDb para calificar sus películas.

Proceso y método

El estudio se hizo en base a 50.000 opiniones recopiladas de Internet Media DataBase (IMDB).

El entorno utilizado para la implementación fue Google Collaboratory, con el lenguaje de programación Python; dentro de las librerías utilizadas se encuentran librerías para cálculos matemáticos tales como Numpy y Pandas y de enfoque al deep-learning como Keras y Tensorflow.

Dentro de las técnicas empleadas se encuentran: Natural Language Processing (NLP), de la mano de una red neuronal recurrente LSTM (Long Short - Term Memory) con una capa de Embedding. Se utilizó un encoding obtenido de la librería TensorFlow.




Figura 1. Procesamiento de lenguaje natural




Figura 2. Arquitectura capa LSTM

Resultados

Con los resultados obtenidos, se observó que la arquitectura de la red neuronal recurrente es un buen modelo para abarcar el problema de procesamiento de lenguaje natural (NLP).

En las siguientes figuras se reflejaron los puntajes obtenidos al hacer el entrenamiento de la RNN con los dos tipos de dataset, en las cuales se evidenció un resultado satisfactorio y similar en las dos formas del entrenamiento.

Los resultados en las pruebas de reseñas recientes de IMDb, presentaron una sensibilidad y mejoría en los resultados, según el preprocesamiento del texto que se tenía antes de ingresarlos a la red neuronal. A su vez, se puede observar de forma más visual el funcionamiento de la inteligencia artificial.

Tabla 1. Métricas

	Simple dataset	TF dataset
Accuracy	0.8565	0.8602
RMSE	0.1434	0.13976




Gráfico 1. Train Accuracy Score

Conclusiones

- Las redes neuronales son una excelente opción para abarcar el problema de NLP.
- El preprocesamiento de los datos es un factor clave para obtener un resultado satisfactorio.
- Dado que se obtuvieron resultados similares con ambos datasets, es posible trabajar desde un dataset propio, el cual puede ampliarse con más reviews de IMDb haciéndolo más robusto, sin valerse así del dataset de tensorflow, de forma que se puede hacer el preprocesamiento y embedding según parezca adecuado.

Trabajo Futuro

Se consideraron un par de ideas para extender este trabajo y enriquecer el conocimiento y la apropiación del Deep Learning:

- Estimar una puntuación que tendría la review según la intensidad de los adjetivos utilizados (“La película es una obra maestra” no es lo mismo a “la película está bien”).
- Crear una red neuronal que se valga de embeddings pre-entrenados, tales como “Fast-text” o “Word2vec”.

Información de contacto

Santiago Castro Duitama, Email: sduitema@gmail.com
Christian Ruiz Lagos, Email: chrismcruiz@gmail.com
Kevin Dlaikan Castillo, Email: kdlaikanj@gmail.com

Docente: Gustavo Garzón, gustavo.garzon@saber.uis.edu.co

Referencias Bibliográficas (en formato APA)

1. N. L. (2019, March 09). IMDB Dataset of 50K Movie Reviews. Retrieved September 06, 2020, from https://www.tensorflow.org/datasets/catalog/imdb_reviews
2. Imdb reviews - TensorFlow Datasets. (n.d.). Retrieved September 06, 2020, from https://www.tensorflow.org/datasets/catalog/imdb_reviews
3. Dwivedi, P. (2018, June 28). Training and Visualising Word Vectors. Retrieved September 06, 2020, from <https://towardsdatascience.com/training-and-visualising-word-vectors-2f946c6430f8>
4. Ranvir, H. (2020, April 25). Intuitive guide to word embedding, RNN (SimpleRNN, LSTM) with step by step implementation in keras... Retrieved September 06, 2020, from <https://medium.com/@hemantranvir/spam-detection-using-rnn-simplernn-lstm-with-step-by-step-explanation-530367608071>
5. Text classification with an RNN : TensorFlow Core. (n.d.). Retrieved September 06, 2020, from https://www.tensorflow.org/tutorials/text/text_classification_rnn
6. Text classification with TensorFlow Hub: Movie reviews. (n.d.). Retrieved September 06, 2020, from https://tensorflow.google.cn/tutorials/keras/text_classification_with_hub?hl=en